

Laporan Teknis Komprehensif

Coding Camp 2026 powered by DBS Foundation

ID Tim Capstone Project: CC-26-PSU105

Tema Capstone : Future Ready Work and Economy

Nama/Judul Proyek : Workaholic: Perancangan Web Rekomendasi Kerja
Berbasis Deep Learning

List Anggota :

1. CFCC613D6X1103 - Gravidya Syahidna Maiwa - Full-Stack Web Developer - **Aktif**
2. CACC246D6X2003 - Syifa Cahya Maryana- AI Engineer - **Aktif**
3. CDCC747D6X2009 - Annisa Fitri Purnama- Data Scientist - **Aktif**
4. CACC246D6X2200 - Ghina Muslimah- AI Engineer - **Aktif**
5. CDCC676D6X2650 - Frida Fatma Salsabila- Data Scientist - **Aktif**
6. CFCC747D6X2775 - Nazwa Aulia Putri- Full-Stack Web Developer - **Aktif**

A. Latar Belakang

Indonesia menghadapi tantangan besar dalam penyerapan tenaga kerja fresh graduate. Berdasarkan data BPS 2023, tingkat pengangguran terbuka di kalangan lulusan perguruan tinggi mencapai 5,18%, dengan mayoritas kesulitan menavigasi platform job portal yang bersifat general dan tidak memberikan panduan yang spesifik untuk pencari kerja entry level. Platform yang ada seperti LinkedIn, Glints, dan Jobstreet masih memerlukan user untuk mencari dan memfilter lowongan secara manual tanpa rekomendasi yang dipersonalisasi berdasarkan profil dan skill yang dimiliki

B. Problem Discovery

Bagaimana membangun sistem rekomendasi pekerjaan berbasis AI yang mampu menganalisis CV secara otomatis dan memberikan rekomendasi posisi pekerjaan serta estimasi gaji yang relevan bagi fresh graduate dan pencari kerja entry level di Indonesia?

C. Pertanyaan Bisnis

PB 1: Kategori pekerjaan apa yang paling banyak dibutuhkan di Indonesia berdasarkan data lowongan 2021-2022, dan apakah dominasi kategori tersebut konsisten di semua kota besar?

- PB 2: Kota mana yang paling banyak membuka lowongan kerja di Indonesia berdasarkan data 2021-2022, dan bagaimana persebarannya dibandingkan dengan kota-kota di luar Pulau Jawa?

- PB 3: Bagaimana perbandingan rata-rata kisaran gaji antar kategori pekerjaan di Indonesia berdasarkan data 2021-2022, dan kategori mana yang menawarkan gap terbesar antara gaji minimum dan maksimum?

- PB 4: Apakah tipe pekerjaan (Full-time, Contract, Internship) berpengaruh terhadap kisaran gaji yang ditawarkan pada kategori yang sama?

- PB 5: Bagaimana distribusi lowongan kerja berdasarkan tipe pekerjaan, dan apakah ada perbedaan signifikan antar kota?

D. Tujuan

- Membangun model klasifikasi kategori pekerjaan berbasis teks CV dengan akurasi minimal 85%.
- Membangun model estimasi gaji berdasarkan kategori dan lokasi pekerjaan.
- Menghasilkan sistem ekstraksi skill otomatis dari teks CV menggunakan skill dictionary.
- Menyediakan dataset bersih dan siap pakai untuk tim AI Engineer.
- Menghasilkan insight berbasis data untuk menjawab 5 pertanyaan bisnis yang telah ditetapkan

E. Pengumpulan Data (Gathering Data)

1. Sumber Data

Dataset yang digunakan adalah hasil crawling lowongan kerja dari Jobstreet Indonesia yang tersedia secara publik di platform Kaggle dengan identifikasi dataset azizainunnajib/jobs-crawling. Dataset ini merupakan kompilasi data harian yang dikumpulkan selama periode Desember 2021 hingga Agustus 2022.

Sumber	Jobstreet Indonesia via Kaggle (azizainunnajib/jobs-crawling)
Periode Data	Desember 2021 — Agustus 2022
Format	CSV (mergeFile.csv)
Ukuran File	285 MB
Total Baris	623.610 baris
Total Kolom	24 kolom
Lisensi	Publik — tersedia di Kaggle

2. Deskripsi Kolom Utama

Kolom	Tipe Data	Deskripsi
JobTitle	object	Judul/posisi pekerjaan
companyName	object	Nama perusahaan pembuka lowongan
categoriesName	object	Kategori bidang pekerjaan (Bahasa Indonesia)
locations	object	Lokasi Pekerjaan
employment	object	Tipe pekerjaan (full time, contract, dll)
description	object	Deskripsi lengkap pekerjaan
sellingPoints	object	Poin unggulan lowongan dari perusahaan
salaryMin	float64	Gaji minimum dalam IDR
salaryMax	float64	Gaji maksimal dalam IDR
salarycurrency	object	Mata uang gaji (mayoritas IDR)

Evidence: Dataset dikumpulkan dengan metode crawling harian sehingga terdapat banyak entri duplikat untuk lowongan yang sama. Hal ini diatasi pada tahap cleaning dengan deduplication berbasis kombinasi kolom jobTitle + companyName + locations. Jumlah baris berkurang dari 623.610 menjadi 241.820 setelah proses deduplication

3. Penilaian Data (Assesing Data)

3.1 Missing Values

Kolom	Jumlah Kosong	Persentase	Keterangan
description	377.437	60.5%	Tidak semua perusahaan mengisi deskripsi
employment	264.959	42.5%	Di-fillna dengan 'full_time'
salaryMin/salaryMax	529.144	84.9%	Hanya dipakai di subset df_salary
salaryTerm	-99.9%	-99.9%	Tidak digunakan, terlalu banyak kosong
companyDescription	-99.4%	-99.4%	Tidak digunakan, terlalu banyak kosong
companyName	11.182	1.8%	Dibiarkan kosong, tidak kritis

3.2 Duplikat

Terdapat 381.790 baris duplikat (61.2% dari total data) yang terjadi karena metode pengumpulan data harian — lowongan yang sama muncul berulang kali selama masa aktif penayangan. Duplikat diidentifikasi berdasarkan kombinasi kolom jobTitle + companyName + locations

3.3 Tipe Data

Tipe Data	Jumlah Kolom	Kolom
object	17	jobTitle, companyName, categoriesName,

		locations, employment, dll
float64	5	salaryMin, salaryMax, companyPrivate, dl
bool	2	isClassified, has_description (setelah cleaning)

Insight Assessing: Kolom salaryMin dan salaryMax tersimpan sebagai object (string) di data mentah karena terdapat nilai non-numerik. Konversi ke float64 dilakukan menggunakan `pd.to_numeric(errors='coerce')` pada tahap cleaning. Kolom categoriesName terkadang berisi kode ID numerik alih-alih nama kategori teks — baris ini dibuang pada tahap filtering

4. Pembersihan Data (Cleaning Data)

4.1 Langkah-langkah Cleaning

a. Deduplication

Menghapus duplikat berdasarkan kombinasi jobTitle + companyName + locations. Hasil: berkurang dari 623.610 menjadi 241.820 baris (minus 61.2%).

b. Filter Kategori Valid

Membuang baris yang kolom categoriesName-nya berupa ID numerik atau kode 'jobstreet-id-XXXXX' yang tidak informatif sebagai label kategori.

c. Pembuatan Kolom full_text

Menggabungkan jobTitle + description + sellingPoints menjadi satu kolom full_text sebagai input utama model NLP. HTML tag, URL, dan karakter khusus dibersihkan menggunakan regex.

d. Normalisasi Employment

Mengisi nilai kosong di kolom employment dengan 'full_time' sebagai default. Format distandarisasi: full_time menjadi Full-time, part_time menjadi Part-time, dst

e. Konversi Tipe Data Gaji

salaryMin dan salaryMax dikonversi dari object ke float64 menggunakan `pd.to_numeric(errors='coerce')`. Nilai non-numerik menjadi NaN.

f. Penambahan Flag Kolom

has_description: True jika full_text lebih dari 100 karakter.

salary_available: True jika salaryMin dan salaryMax keduanya tidak null.

4.2 Ringkasan Hasil Cleaning

Metrik	Sebelum	Sesudah	Selisih
Total Baris	623.610	241.820	Minus 381.790 (minus 61.2%)
Duplikat	381.790	0	Semua dihapus
Kolom Digunakan	24	13	Kolom tidak relevan dibuang
Missing Values (description)	60.5%	40.8%	Berkurang setelah dedup
Missing Values (employment)	42.5%	0%	Di-fillna 'full_time'
Baris dengan deskripsi lengkap	~39%	~59%	Meningkat setelah dedup

5. Explaratory Data Analysis (EDA)

EDA dilakukan untuk memahami karakteristik umum dataset sebelum analisis mendalam. Tiga aspek utama yang dieksplorasi adalah distribusi tipe pekerjaan, kelengkapan deskripsi lowongan, dan ketersediaan data gaji.

5.1 Distribusi Tipe Pekerjaan

Tipe Pekerjaan	Jumlah	Persentase
Full-Time	260.679	87.1%
Contract	31.770	10.6%
Part-Time	2.221	0.7%
Internship	2.015	0.7%
Temporary	923	0.3%
Lainnya	212	0.1%


Insight: Full-time mendominasi 87% dari seluruh lowongan, mencerminkan preferensi pasar kerja Indonesia yang masih sangat berorientasi pada karyawan tetap. Proporsi internship yang kecil (0.7%) menunjukkan bahwa platform Jobstreet kurang digunakan untuk posisi magang.

5.2 Kelengkapan Data

Metrik	Nilai
Baris dengan deskripsi lengkap (lebih dari 100 karakter)	138.000 (59.2%)
Baris tanpa deskripsi / deskripsi pendek	~103.820 (40.8%)
Baris dengan data gaji tersedia	60.477 (25%)
Baris tanpa data gaji	181.343 (75%)

6. Visualisasi & Explanatory Analysis


6.1 Kategori Pekerjaan Terbanyak (PB 1)



Kota	Kategori #1
Bandung	Penjualan / Pemasaran
Jakarta Raya	Penjualan / Pemasaran
Semarang	Penjualan / Pemasaran
Surabaya	Penjualan / Pemasaran
Tangerang	Penjualan / Pemasaran

Insight PB 1: Penjualan/Pemasaran mendominasi dengan 80.967 lowongan — hampir 2.2x lipat kategori terbanyak kedua. Dominasi ini terbukti konsisten di semua kota besar (Jakarta, Surabaya, Bandung, Tangerang, Bali), menunjukkan bahwa kebutuhan tenaga penjualan bersifat merata secara nasional. Kategori IT masuk top 5, mencerminkan pesatnya transformasi digital Indonesia 2021-2022.

6.2 Kota dengan Lowongan Terbanyak (PB 2)




Insight PB 2: Jakarta Raya mendominasi dengan 65.711 lowongan — hampir 2.7x lipat kota terbanyak kedua. Lebih dari 70% lowongan terkonsentrasi di Pulau Jawa, sementara Bali menjadi satu-satunya kota luar Jawa di top 10, didorong oleh sektor pariwisata dan hospitality. Ketimpangan distribusi ini mengindikasikan perlunya pemerataan kesempatan kerja ke luar Pulau Jawa.

6.3 Rata-rata Gaji per Kategori & Gap Min-Max (PB 3)




Insight PB 3: Kategori IT memiliki median gaji tertinggi (Rp 8,0jt) sekaligus gap min-max terbesar (Rp 6,0jt) — mencerminkan variasi level seniority yang tinggi. Menariknya, Penjualan/Pemasaran yang memiliki lowongan terbanyak justru berada di posisi terbawah gaji (Rp 5,4jt), membuktikan bahwa volume lowongan tidak berbanding lurus dengan besaran kompensasi


6.4 Tipe Pekerjaan vs Gaji (PB 4 & 5)



Distribusi Tipe Pekerjaan (Keseluruhan)



■ Full-time ■ Internship
■ Contract ■ Temporary
■ Part-time



Insight PB 4 & 5: Tipe pekerjaan terbukti berpengaruh signifikan terhadap gaji — Full-time menawarkan median gaji tertinggi (Rp 9,0jt), diikuti Contract (Rp 8,0jt) yang sangat kompetitif. Distribusi Full-time (87%) konsisten di semua kota besar, kecuali Bali yang memiliki proporsi Contract dan Temporary lebih tinggi sesuai karakteristik industri pariwisata yang bersifat musiman.

7. Kalibrasi Data Gaji WORKAHOLIC

2024 Data gaji mentah mengandung berbagai anomali yang perlu dibersihkan sebelum digunakan sebagai target prediksi model regresi. Kalibrasi dilakukan dengan empat filter berurutan:

7.1. Filter 1

Mata Uang Hanya mempertahankan baris dengan `salarycurrency = 'IDR'`. Baris dengan mata uang USD, SGD, dan lainnya dibuang karena tidak relevan untuk konteks pasar kerja Indonesia.

Filter 2

Batas Bawah UMR Membuang baris dengan `salaryMin` kurang dari Rp 2.000.000 (di bawah UMR terendah Indonesia). Sebanyak 1.667 baris dengan gaji suspek dibuang.

Filter 3

Batas Atas Outlier Membuang baris dengan salaryMax lebih dari Rp 50.000.000 karena kemungkinan besar merupakan anomali data atau lowongan posisi sangat senior yang tidak relevan untuk segmen entry level.

Filter 4

Konsistensi Min-Max Memastikan salaryMin tidak melebihi salaryMax. Tidak ditemukan anomali (0 baris) untuk kondisi ini

Hasil Kalibrasi

Metrik	Nilai
Total baris setelah kalibrasi	58.487 baris
Rata-rata gaji minimum	Rp 5.881.068
Rata-rata gaji maksimum	Rp 8.352.828
Median salary midpoint	Rp 5.500.000
Kolom target prediksi	$\text{salary_mid} = (\text{salaryMin} + \text{salaryMax}) / 2$

Catatan: Data gaji hanya tersedia untuk 25% dari total lowongan. Hal ini wajar karena banyak perusahaan di Indonesia tidak mencantumkan informasi gaji secara publik. Model estimasi gaji dilatih hanya dari 58.487 baris yang memiliki data gaji valid.

8. Feature Engineering

Feature engineering dilakukan untuk mengubah data teks dan kategorikal menjadi representasi numerik yang dapat diproses oleh model machine learning. Tiga teknik utama digunakan:

8.1 Label Encoding

Kolom kategorik categoriesName, employment, dan locations diubah menjadi representasi integer menggunakan sklearn LabelEncoder. Label Encoding dipilih karena jumlah kategori yang besar — One-Hot Encoding akan menghasilkan dimensi yang terlalu tinggi (81 kategori = 81 kolom baru)

Kolom	Jumlah Nilai Unik	Contoh Mapping
categoriesName	81 kategori	Akuntansi/Keuangan menjadi 0, Bangunan menjadi 1, dst
employment	6 tipe	Full-time menjadi 2, Contract menjadi 0, Internship menjadi 3, dst
locations	~450 lokasi	Bali menjadi 5, Bandung menjadi 6, Jakarta Raya menjadi 89, dst

8.2 TF-IDF Vectorization

Kolom `text_input` (gabungan `jobTitle` + `full_text`) diubah menjadi vektor numerik menggunakan TF-IDF (Term Frequency-Inverse Document Frequency). Parameter yang digunakan:

Parameter	Nilai	Alasan
<code>max_features</code>	5.000	Membatasi 5.000 kata paling informatif untuk efisiensi memori
<code>min_df</code>	5	Mengabaikan kata yang muncul di kurang dari 5 dokumen
<code>max_df</code>	0.85	Mengabaikan kata yang terlalu umum (lebih dari 85% dokumen)
<code>ngram_range</code>	(1, 2)	Menangkap unigram dan bigram untuk konteks lebih kaya
<code>sublinear_tf</code>	True	Menggunakan log normalization untuk mengurangi dominasi frekuensi tinggi satu lowongan pekerja

Hasil TF-IDF: matrix berukuran (138.000, 5.000) — setiap baris merepresentasikan satu lowongan pekerjaan sebagai vektor 5.000 dimensi.

8.3 MinMax Scaling (Normalisasi Gaji)

Kolom salaryMin, salaryMax, dan salary_mid dinormalisasi ke skala 0-1 menggunakan MinMaxScaler agar model regresi tidak bias terhadap skala nilai yang besar (range Rp 2jt - Rp 50jt).

8.4 Skill Dictionary Extraction

Dibangun kamus skill dengan 100+ skill dalam 10 kategori sebagai pengganti dataset CV berlabel yang tidak tersedia secara publik. Ekstraksi dilakukan menggunakan regex word-boundary matching

Kategori	Jumlah Skill	Contoh
Programming Language	14	Python, Java, JavaScript, PHP, Kotlin
Frontend	14	React, Vue, Angular, HTML, CSS, Tailwind
Backend	12	Laravel, Django, Node.js, FastAPI, Spring
Database	10	MySQL, PostgreSQL, MongoDB, Redis, SQL
Data & AI	15	Machine Learning, TensorFlow, Pandas, Tableau
DevOps & Cloud	13	Docker, Kubernetes, AWS, GCP, Linux
Tools & Office	12	Excel, Photoshop, Figma, AutoCAD, Jira
Soft Skills	18	Komunikasi, Leadership, Teamwork, Problem Solving
Mobile	7	Android, iOS, Flutter, React Native
Language	7	English, Mandarin, Japanese, Korean

9. Hasil Akhir & Output

9.1 Dataset Output

File	Ukuran	Deksripsi
loker_clean.csv	241.820 baris x 13 kolom	Dataset bersih utama — untuk dashboard & analisis

df_model.csv	~138.000 baris x 8 kolom	Dataset siap training model klasifikasi & rekomendasi
df_salary.csv	58.487 baris x 9 kolom	Dataset siap training model estimasi gaji

9.2 Model & Encoder Output

File	Deskripsi	Performa
model_job_classifier.pkl	Model klasifikasi kategori pekerjaan dari teks CV	Akurasi: 85.08%
tfidf_vectorizer.pkl	TF-IDF vectorizer untuk transformasi teks	5.000 fitur
le_category.pkl	Label encoder untuk 81 kategori pekerjaan	81 kelas
le_employment.pkl	Label encoder untuk tipe pekerjaan	6 kelas
le_location.pkl	Label encoder untuk lokasi	~450 lokasi
salary_scaler.pkl	MinMaxScaler untuk normalisasi gaji	Range 0-1

9.3 Performa Model Klasifikasi

Model Job Classifier dilatih menggunakan Logistic Regression dengan TF-IDF features dan class weight balancing untuk mengatasi ketidakseimbangan distribusi kategori:

Metrik	Train Set	Validation Set	Test Set
Accuracy	—	85.84%	85.08%
Weighted F1	—	—	0.86
Macro F1	—	—	0.76

Jumlah Data	9.130 baris	1.956 baris	1.957 baris
-------------	-------------	-------------	-------------

Catatan Performa: Kategori dengan data kurang dari 100 baris seperti DevOps & Cloud (f1: 0.37) dan Web Developer (f1: 0.49) masih di bawah rata-rata. Hal ini disebabkan keterbatasan jumlah sampel training — class weight balancing membantu namun tidak sepenuhnya mengkompensasi kurangnya data. Peningkatan performa dapat dilakukan dengan penambahan data untuk kategori minoritas.

10. Kesimpulan

PB 1 — Kategori Pekerjaan

Penjualan/Pemasaran mendominasi pasar kerja Indonesia (80.967 lowongan) dan konsisten menjadi kategori terbanyak di semua kota besar. Kategori IT masuk top 3, mencerminkan akselerasi transformasi digital Indonesia.

PB 2 — Distribusi Geografis

Jakarta Raya mendominasi dengan 65.711 lowongan. Lebih dari 70% lowongan terkonsentrasi di Pulau Jawa, menunjukkan ketimpangan distribusi kesempatan kerja yang signifikan.

PB 3 — Gaji per Kategori

IT memiliki median gaji tertinggi (Rp 8,0jt) sekaligus gap min-max terbesar. Volume lowongan tidak berbanding lurus dengan gaji — Penjualan/Pemasaran memiliki lowongan terbanyak namun gaji terendah di antara top kategori.

PB 4 — Tipe Pekerjaan vs Gaji

Tipe pekerjaan berpengaruh signifikan terhadap gaji. Full-time menawarkan Rp 9,0jt dan Contract Rp 8,0jt — keduanya jauh melampaui Part-time dan Internship.

PB 5 — Distribusi Tipe per Kota

Full-time konsisten mendominasi di semua kota. Bali menjadi pengecualian dengan proporsi Contract dan Temporary lebih tinggi sesuai karakteristik industri pariwisata. Model AI Model Job Classifier berhasil mencapai akurasi test 85.08% — memenuhi target minimal 85% yang ditetapkan. Dataset bersih siap diserahkan ke tim AI Engineer.